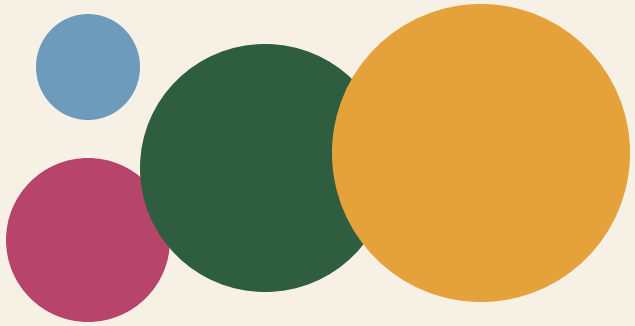
Classificazione *del Testo*

Dal testo alle parole, dalle parole ai numeri,
dai numeri alla predizione con i centroidi.



Classificare un testo significa *assegnargli una categoria* in base al suo contenuto.

Sentiment

«Questo film è fantastico!»

Positivo

Argomento

«La partita finì 3-1»

Sport

Intento

«Vorrei ordinare una pizza»

Ordine

Dal testo grezzo alla predizione



Idea chiave

Il computer trasforma ogni testo in un vettore di numeri. Poi calcola il “centro” (centroide) di ogni categoria. Un testo nuovo viene classificato scegliendo il centroide più vicino.

Dal testo grezzo alla predizione

Preprocess Text: Fondamentale per pulire i dati.
Permette di:

- Trasformare tutto in minuscolo.
- Rimuovere la punteggiatura e i numeri.
- Filtrare le stop words (parole comuni come "il", "di", "e" che non portano significato).
- Eseguire lo stemming o la lemmatizzazione (ridurre le parole alla loro radice, es. "correndo" diventa "correre").

Bag of Words = *sacchetto di parole*

Ignoriamo l’ordine delle parole e contiamo solo quante volte appare ogni parola.

TESTO ORIGINALE

«Il gatto nero salta sul tetto»

Ordine e grammatica
sono importanti per noi…

SACHETTO DI PAROLE

il ×1	gatto ×1	nero ×1
salta ×1	sul ×1	tetto ×1

Bag of Words = *sacchetto di parole*

Ignoriamo l’ordine delle parole e contiamo solo quante volte appare ogni parola.

TESTO ORIGINALE

«gatto nero
salta tetto»

Ordine e grammatica
sono importanti per noi…

SACHETTO DI PAROLE



Dagli esempi di training alla matrice di numeri

Ogni riga = un esempio · Ogni colonna = una parola · Ultima colonna = etichetta

Esempio	gatto	cane	bello	brutto	adoro	odio	Etichetta
«Il gatto è bello»	1	0	1	0	0	0	Positivo
«Adoro il cane»	0	1	0	0	1	0	Positivo
«Il film è brutto»	0	0	0	1	0	0	Negativo
«Odio questo gatto»	1	0	0	0	0	1	Negativo

Questa matrice è ciò che il modello "vede" durante l'addestramento.

Le parole "bello" e "adoro" appaiono solo con Positivo · "brutto" e "odio" solo con Negativo

Centroide = *il “centro” di una classe*

Si calcola facendo la media di tutti i vettori degli esempi di quella classe.

CLASSE POSITIVO

Esempi:

`[1, 0, 1, 0, 0, 0]  +  [0, 1, 0, 0, 1, 0]`

Media (centroide):

`[ 0.5 ,  0.5 ,  0.5 ,  0 ,  0.5 ,  0 ]`

Parole “tipiche”: gatto, cane, bello, adoro

CLASSE NEGATIVO

Esempi:

`[0, 0, 0, 1, 0, 0]  +  [1, 0, 0, 0, 0, 1]`

Media (centroide):

`[ 0.5 ,  0 ,  0 ,  0.5 ,  0 ,  0.5 ]`

Parole “tipiche”: gatto, brutto, odio

Formula semplice: media aritmetica componente per componente

Centroide di una classe = (somma di tutti i vettori della classe) ÷ (numero di esempi)

Per ogni parola: media = (conteggi di quella parola negli esempi) / N

Esempio dettagliato — classe Positivo (2 esempi)

Parola	Esempio 1	Esempio 2	Somma	Media
gatto	1	0	1	0.5
cane	0	1	1	0.5
bello	1	0	1	0.5
brutto	0	0	0	0
adoro	0	1	1	0.5
odio	0	0	0	0

Un testo mai visto diventa un vettore nello stesso spazio

NUOVO TESTO

«Adoro questo gatto bello»



VETTORE

`[ 1 , 0 , 1 , 0 , 1 , 0 ]`

Vocabolario: gatto · cane · bello · brutto · adoro · odio

gatto	cane	bello	brutto	adoro	odio
1	0	1	0	1	0

Ora confrontiamo questo vettore con i due centroidi…

Calcoliamo la distanza dal vettore

Formula della distanza euclidea

$$d(x,y) = \sqrt{\sum_{i=1}^{n} (y_i - x_i)^2}$$

VETTORE INCOGNITO

[1 , 0 , 1 , 0 , 1 , 0]

CENTROIDE POSITIVO

[0.5 , 0.5 , 0.5 , 0 , 0.5 , 0]

DISTANZA

D(x,y)=sqr((0.5-1)^2+(0.5-0)^2+(0.5-1)^2+(0-0)^2+(0.5-1)^2+(0-0)^2)

D(x,y) = sqr(1)

D(x,y)=1

Calcoliamo la distanza dal vettore

Formula della distanza euclidea

$$d(x,y) = \sqrt{\sum_{i=1}^{n} (y_i - x_i)^2}$$

VETTORE INCOGNITO

[1 , 0 , 1 , 0 , 1 , 0]

CENTROIDE NEGATIVO

[0.5 , 0 , 0 , 0.5 , 0 , 0.5]

DISTANZA

D(x,y)=sqr((0.5-1)^2+(0-0)^2+(0-1)^2+(0.5-0)^2+(0-1)^2+(0.5-0)^2)

D(x,y) = sqr(2,75)

D(x,y)= 1,65

Si sceglie la classe del centroide più vicino

Predizione: POSITIVO

perché distanza da Positivo (1) < distanza da Negativo (1.65)

1. Trasforma il nuovo testo in vettore Bag of Words
2. Calcola (o recupera) i centroidi di ogni classe
3. Misura la distanza dal nuovo vettore a ogni centroide
4. Assegna la classe del centroide più vicino

Cosa avete fatto voi (e cosa succede dietro)

VOI AVETE FATTO

- → Creato un progetto di testo
- → Inserito esempi per ogni etichetta
- → Addestrato il modello (Train)
- → Usato i blocchi Scratch per predire
- → Testato con frasi nuove

DIETRO LE QUINTE

- → Costruzione del vocabolario e matrice
- → Calcolo dei centroidi di ogni classe
- → Conversione del nuovo testo in vettore
- → Confronto delle distanze dai centroidi
- → Scelta della classe del centroide più vicino

Si calcola la distanza (o similarità) dal nuovo vettore a ciascun centroide

Nuovo testo

`[1, 0, 1, 0, 1, 0]`

Centroide Positivo

`[0.5, 0.5, 0.5, 0, 0.5, 0]`

Centroide Negativo

`[0.5, 0, 0, 0.5, 0, 0.5]`

Distanza euclidea (semplificata): più piccola → più vicino

Distanza da Positivo

Differenze piccole sulle
parole “gatto, bello, adoro”
→ distanza ≈ 1

Distanza da Negativo

Differenze grandi sulle
parole “bello, adoro, brutto, odio”
→ distanza ≈ 1.65

PRO e CONTRO

PRO

→ È un metodo molto semplice, intuitivo e ideale per alimentare algoritmi di machine learning (come la classificazione dello spam)

CONTRO

→ Ignora il contesto e l'ordine delle parole (le frasi "Il gatto insegue il cane" e "Il cane insegue il gatto" avrebbero quasi lo stesso identico vettore di conteggi) e genera vettori molto grandi e pieni di zeri (vettori sparsi) se il testo è lungo.

VARIANTI

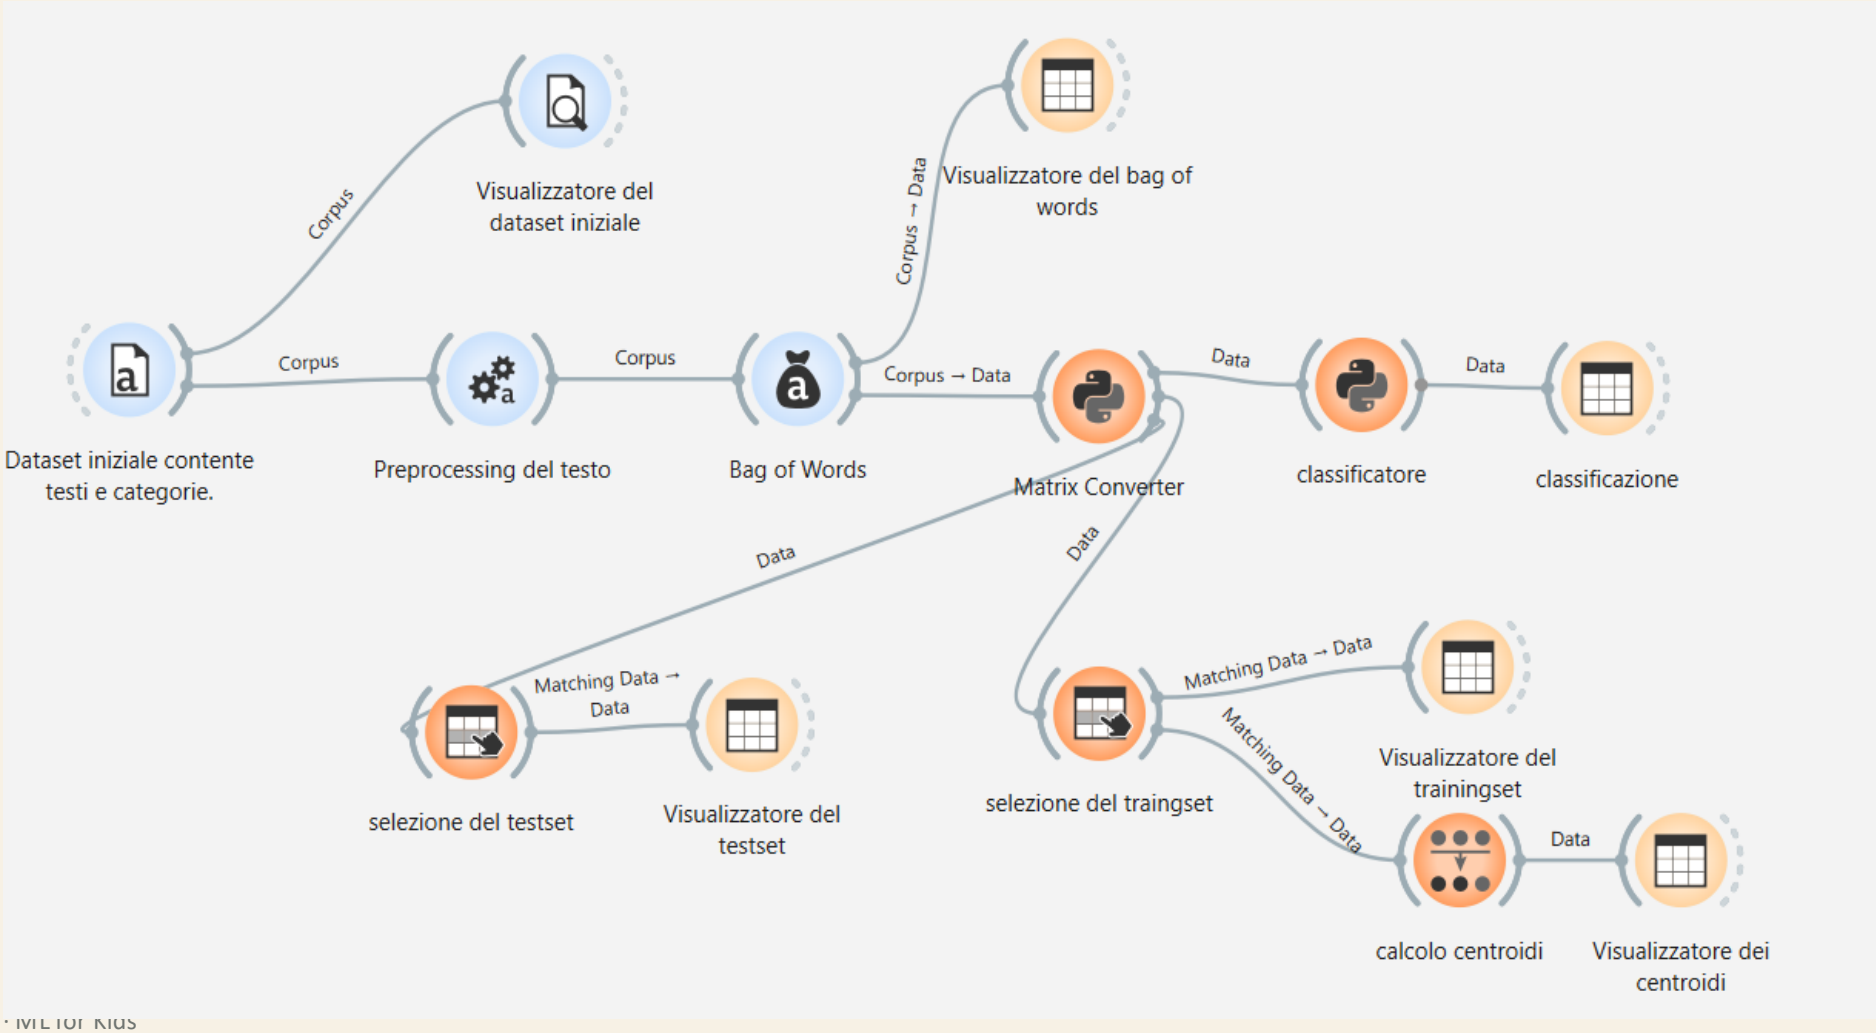
VARIANTE STRUTTURA DATI

Ogni vettore rappresenta la frequenza con cui quella parola compare nella frase

VARIANTE DEL MODELLO

Il modello TF-IDF (Term Frequency - Inverse Document Frequency) risolve il più grande difetto del Bag of Words semplice: il fatto che le parole comunissime (come "il", "di", "è") abbiano i punteggi più alti solo perché compaiono ovunque, pur non offrendo alcuna informazione utile per capire l'argomento di un testo.TF-IDF pesa le parole combinando due concetti: premia le parole che appaiono molte volte in un singolo documento, ma le penalizza se queste appaiono spesso in tutti i documenti della raccolta.

ORANGE


Corpus
Visualizzatore del dataset iniziale
Corpus → Data
Visualizzatore del bag of words
Corpus
Corpus
Corpus → Data
Data
Data
Dataset iniziale contente testi e categorie.
Preprocessing del testo
Bag of Words
Matrix Converter
classificatore
classificazione
Data
Data
Matching Data → Data
Matching Data → Data
Matching Data → Data
selezione del testset
Visualizzatore del testset
selezione del traingset
Visualizzatore del trainingset
Data
calcolo centroidi
Visualizzatore dei centroidi

VALUTAZIONE DEL MODELLO – LA MATRICE DI CONFIDENZA

True Positives (TP)

Classe positiva predetta correttamente.
Es. Malattia identificata con successo.

False Positives (FP)

Errore di Tipo I: Falso allarme.
Classe negativa predetta come positiva.

False Negatives (FN)

Errore di Tipo II: Omissione critica.
Classe positiva predetta come negativa.

True Negatives (TN)

Classe negativa predetta correttamente.
Es. Utente sano riconosciuto tale.

VALUTAZIONE DEL MODELLO – GLI INDICI

Accuracy (Accuratezza)

FORMULA:

(TP + TN) / Totale

OBIETTIVO:

- Misura l'efficacia globale.
- La percentuale di previsioni corrette sul totale.

NOTE CRITICHE:

Fuorviante con classi sbilanciate (es. 95% classe maggioritaria).

Precision (Precisione)

FORMULA:

TP / (TP + FP)

OBIETTIVO:

- Minimizza i Falsi Positivi.
- Indica quanto il modello è affidabile quando predice la classe positiva.

NOTE CRITICHE:

Filtri antispam, concessione credito (costo FP alto).

Recall (Sensibilità)

FORMULA:

TP / (TP + FN)

OBIETTIVO:

- Minimizza i Falsi Negativi.
- Cos'è: Capacità del modello di trovare tutti i casi positivi (evita i falsi negativi).

NOTE CRITICHE:

Diagnostica medica, rilevamento frodi/intrusioni (costo FN critico).

F1-Score

FORMULA:

2 *((Prec * Rec) / (Prec + Rec))

OBIETTIVO:

- Media armonica bilanciata
- Media armonica tra Precision e Recall; utile se le classi sono sbilanciate..

NOTE CRITICHE:

Penalizza valori squilibrati; metrica ideale per dati asimmetrici.

VALUTAZIONE DEL MODELLO – GLI INDICI

Metrica	Modello Buono	Modello Cattivo
TP / TN	48 / 47	25 / 25
FP / FN	3 / 2	25 / 25
Accuracy	0.95	0.50
Precision	0.94	0.50
Recall	0.96	0.50
F1-Score	0.95	0.50

- **Modello Buono:** Ha pochi errori, alta capacità di identificare i positivi senza generare falsi allarmi.
- **Modello Cattivo:** Performance pari a un lancio di moneta (50%), non apprende nulla dai dati.